

# Working with AI APIs

Занятие 11 · Инструктор — **Андрей Помелов**



# Как работает AI API?

## Запрос (Prompt)

Вы отправляете текстовый запрос — вопрос, задачу или инструкцию — на сервер AI-модели.

## Ответ (Response)

Модель обрабатывает запрос и возвращает сгенерированный текст. Именно этот цикл лежит в основе любого AI-приложения.

Понимание этого принципа — **ключевой первый шаг** к работе с любым AI API.



# Инструмент: Axios

Для отправки запросов к AI API мы используем **Axios** — популярную JavaScript-библиотеку для HTTP-запросов.

## Установка

Установите Axios  
через npm



## Отправка


Отправьте запрос и  
обработайте ответ



## Конфигурация

Добавьте API-ключ  
и URL запроса

Axios упрощает работу с сетевыми запросами: удобный синтаксис, поддержка промисов и автоматическая обработка JSON-ответов.



# Практика: первый запрос

Начнём с самого простого — отправим запрос к модели **без сложной настройки**.

## Шаг 1

Импортируем Axios и задаём endpoint модели

## Шаг 2

Формируем тело запроса с полем `prompt`

## Шаг 3

Выводим ответ в консоль и анализируем структуру

# Сравнение моделей: TinyLlama vs Gemini

Один и тот же запрос — разные модели — разные результаты. Посмотрим, чем они отличаются.

## **TinyLlama**

Лёгкая модель с небольшим числом параметров.  
Быстрая, работает локально, подходит для простых задач и прототипирования.

## **Gemini**

Мощная модель от Google. Даёт развёрнутые, точные ответы. Лучше справляется со сложными запросами и многоступенчатыми задачами.

 Практический вывод: нет «лучшей» модели — есть модель, подходящая для конкретной задачи.





# Проблема качества ответа

Один и тот же запрос может давать **совершенно разные результаты** — в зависимости от модели, момента и формулировки.

## Недетерминированность

Языковые модели генерируют текст вероятностно — каждый раз ответ может немного отличаться.

## Нечёткий запрос

Размытая формулировка даёт размытый результат. Модель «угадывает» намерение пользователя.

## Параметры модели


Temperature, top-p и другие настройки напрямую влияют на «творческую» и точность ответа.

# Роль prompt

Prompt — это не просто вопрос. Это **инструкция для модели**. Чем точнее формулировка, тем полезнее ответ.

⚠ Плохой prompt: «Расскажи про API»

✅ Хороший prompt: «Объясни, что такое REST API, в двух предложениях для начинающего разработчика»



# Как выбрать подходящую модель?

Разные задачи требуют разных инструментов. Ориентируйтесь на три ключевых критерия:



## Скорость

Нужен быстрый ответ в реальном времени? Выбирайте лёгкие модели вроде TinyLlama.



## Сложность задачи

Анализ, рассуждения, код — используйте мощные модели: Gemini, GPT-4, Claude.



## Стоимость

Большие модели = выше цена за токен. Для прототипов и тестов экономьте бюджет.





# Итог занятия

Качественный результат — это всегда **сочетание двух факторов**.

## ◆ **Правильный Prompt**

Чёткая, структурированная формулировка с контекстом и ожидаемым форматом ответа.

## ◆ **Подходящая модель**

Выбор модели под задачу: скорость, глубина анализа, стоимость запроса.